Correction TD STAT et OPT 2025/2026

Exercice 1

Soit p_n la probabilité que l'appareil fonctionne à l'instant t_n. On sait qu'à l'instant 0, il fonctionne : $p_0 = 1$.

À l'instant t_{n+1}, l'appareil peut être en marche dans deux cas :

- il fonctionnait à t_n (probabilité p_n) et y reste avec probabilité a ;
- il était en panne à t_n (probabilité $1 - p_n$) et se remet en marche avec probabilité $1 - b$ (car s'il est en panne, la probabilité d'être encore en panne à t_{n+1} est b, donc celle de fonctionner est $1 - b$).

D'aprés le théorème des probabilités totales:

$$p_{n+1} = a\,p_n + (1-b)(1-p_n) = (a+b-1)p_n + (1-b).$$

C'est une récurrence affine linéaire. On cherche d'abord la solution particulière constante p :

$$p = (a+b-1)p+(1-b) \quad \Rightarrow \quad p(1-(a+b-1)) = 1-b \quad \Rightarrow \quad p(2-a-b) = 1-b.$$

Si $a + b \neq 2$ (toujours vrai car $a, b \in]0, 1[$), on a

$$p = \frac{1-b}{2-a-b}.$$

$$p_n = C\,(a+b-1)^n + \frac{1-b}{2-a-b}.$$

La condition initiale $p_0 = 1$ donne $C + \frac{1-b}{2-a-b} = 1$, soit

$$C = 1 - \frac{1-b}{2-a-b} = \frac{2-a-b-(1-b)}{2-a-b} = \frac{1-a}{2-a-b}.$$

Finalement,

$$\boxed{p_n = \frac{1-a}{2-a-b}\,(a+b-1)^n + \frac{1-b}{2-a-b}}.$$

Exercice 2

La particule évolue sur $\{0, 1, \ldots, N\}$ avec 0 et N absorbants. q_n est la probabilité d'être absorbé en 0 en partant de n.

1) a) Si la particule part de 0, elle est déjà à l'extrémité 0, donc $q_0 = 1$. Si elle part de N, elle est à l'autre extrémité, donc elle ne peut jamais s'arrêter en 0 : $q_N = 0$.

b) Pour $1 \leq n \leq N-1$, on raisonne sur le premier pas. De n, la particule va en $n+1$ avec probabilité p et en $n-1$ avec probabilité $q = 1-p$. Par la formule des probabilités totales,

$$q_n = p\,q_{n+1} + q\,q_{n-1}.$$

(C'est une récurrente linéaire de second ordre à coefficients constants

son terme général se déduit de résolution de son équation caractéristique)

c) L'équation caractéristique de systeme précédent est $pr^2 - r + q = 0$.

Les racines sont $r_1 = 1$ et $r_2 = \frac{q}{p}$. Donc deux cas :

- **Si** $p \neq 1/2$ $(p \neq q)$: les deux racines sont distinctes. La solution générale est $q_n = A + B\left(\frac{q}{p}\right)^n$. Avec $q_0 = 1$ et $q_N = 0$:

$$\begin{cases} A + B = 1 \\ A + B\left(\frac{q}{p}\right)^N = 0 \end{cases} \Rightarrow A = \frac{-\left(\frac{q}{p}\right)^N}{1 - \left(\frac{q}{p}\right)^N}, \quad B = \frac{1}{1 - \left(\frac{q}{p}\right)^N}.$$

  Donc

$$q_n = \frac{1 - \left(\frac{q}{p}\right)^n}{1 - \left(\frac{q}{p}\right)^N}.$$

- **Si** $p = 1/2$ $(p = q = 1/2)$: racine double $r_1 = r_2 = 1$ La solution générale est $q_n = A + Bn$. Avec $q_0 = 1$ et $q_N = 0$:

$$A = 1, \quad 1 + BN = 0 \Rightarrow B = -\frac{1}{N}.$$

  Ainsi

$$q_n = 1 - \frac{n}{N}.$$

2) La probabilité p_n de s'arrêter en N s'obtient par symétrie (en échangeant p et q, et 0 et N). Donc :

$$p_n = \begin{cases} \dfrac{1 - \left(\frac{p}{q}\right)^n}{1 - \left(\frac{p}{q}\right)^N} & \text{si } p \neq 1/2, \\ \dfrac{n}{N} & \text{si } p = 1/2. \end{cases}$$

3) On a $p_n + q_n = 1$ dans tous les cas (vérification immédiate par les formules). La particule finit presque sûrement par toucher une extrémité car la marche est récurrente sur un intervalle fini avec barrières absorbantes. La probabilité qu'elle ne s'arrête jamais est donc nulle :

$$\boxed{p_n + q_n = 1 \quad \text{et} \quad \mathbb{P}(\text{arrêt jamais}) = 0}.$$

Exercice 3

Énoncé : Dans une population, une personne sur 10 000 souffre d'une pathologie. Un laboratoire pharmaceutique met sur le marché un test sanguin. Celui-ci est positif chez 99 % des malades mais aussi faussement positif chez 0,1 % des personnes non atteintes. Un individu passe ce test et obtient un résultat positif. Quelle est sa probabilité d'être malade ? Qu'en conclure ?

Correction

Notons les événements :

- M : "la personne est malade",
- T^+ : "le test est positif".

On a $P(M) = \frac{1}{10000} = 0,0001$, $P(\overline{M}) = 0,9999$. La sensibilité : $P(T^+ \mid M) = 0,99$. Le faux positif : $P(T^+ \mid \overline{M}) = 0,001 = 0,1\%$.

On cherche $P(M \mid T^+)$. Par la formule de Bayes :

$$P(M \mid T^+) = \frac{P(T^+ \mid M)\, P(M)}{P(T^+ \mid M)P(M) + P(T^+ \mid \overline{M})P(\overline{M})}.$$

Calculons :

$$P(M \mid T^+) = \frac{0,99 \times 0,0001}{0,99 \times 0,0001 + 0,001 \times 0,9999} = \frac{0,000099}{0,000099 + 0,0009999} = \frac{0,000099}{0,0010989} \approx 0,0901.$$

Ainsi, la probabilité d'être réellement malade sachant que le test est positif est d'environ $9,01\%$.

Conclusion : Bien que le test semble fiable (sensibilité 99%, spécificité 99,9%), la faible prévalence de la maladie rend la valeur prédictive positive faible. La majorité des positifs sont des faux positifs. Ce phénomène est classique en dépistage de maladies rares.

Exercice 4

Énoncé :

1. Énoncer et démontrer la formule de Bayes.
2. On dispose de 100 dés dont 25 sont pipés. Pour chaque dé pipé, la probabilité d'obtenir le chiffre 6 lors d'un lancer vaut $\frac{1}{2}$.
   (a) On tire un dé au hasard parmi les 100 dés. On lance ce dé et on obtient le chiffre 6. Quelle est la probabilité que ce dé soit pipé ?
   (b) Soit $n \in \mathbb{N}^*$. On tire un dé au hasard parmi les 100 dés. On lance ce dé n fois et on obtient n fois le chiffre 6. Quelle est la probabilité p_n que ce dé soit pipé ?
   (c) Déterminer $\lim\limits_{n \to +\infty} p_n$. Interpréter ce résultat.

Correction

1) Formule de Bayes **Énoncé :** Soient $A_1, A_2, \ldots, A_n$ des événements formant une partition de l'univers (mutuellement exclusifs et de réunion Ω), avec $P(A_i) > 0$ pour tout i. Alors pour tout événement B de probabilité non nulle et pour tout k,

$$P(A_k \mid B) = \frac{P(B \mid A_k)P(A_k)}{\sum_{i=1}^{n} P(B \mid A_i)P(A_i)}.$$

Démonstration : Par définition de la probabilité conditionnelle,

$$P(A_k \mid B) = \frac{P(A_k \cap B)}{P(B)}.$$

Or $P(A_k \cap B) = P(B \mid A_k)P(A_k)$ et $P(B) = \sum_{i=1}^{n} P(B \cap A_i) = \sum_{i=1}^{n} P(B \mid A_i)P(A_i)$ (car les A_i forment une partition). D'où la formule.

2) Application aux dés Soit P l'événement "le dé est pipé". On a $P(P) = \frac{25}{100} = 0,25$, $P(\overline{P}) = 0,75$. Pour un dé pipé : probabilité d'obtenir $6 = \frac{1}{2}$; pour un dé non pipé (équilibré) : probabilité d'obtenir $6 = \frac{1}{6}$.

a) On obtient un 6 au premier lancer. Notons A : "obtenir 6". Par Bayes :

$$P(P \mid A) = \frac{P(A \mid P)P(P)}{P(A \mid P)P(P) + P(A \mid \overline{P})P(\overline{P})} = \frac{\frac{1}{2} \times 0,25}{\frac{1}{2} \times 0,25 + \frac{1}{6} \times 0,75}.$$

Calculons : numérateur $= 0,125$; dénominateur $= 0,125 + 0,125 = 0,25$. Donc $P(P \mid A) = \frac{0,125}{0,25} = 0,5$. La probabilité est $\frac{1}{2}$.

b) On obtient n fois 6 en n lancers. Soit B_n : "n six consécutifs". Alors $P(B_n \mid P) = \left(\frac{1}{2}\right)^n$, $P(B_n \mid \overline{P}) = \left(\frac{1}{6}\right)^n$. Par Bayes :

$$p_n = P(P \mid B_n) = \frac{\left(\frac{1}{2}\right)^n \times 0,25}{\left(\frac{1}{2}\right)^n \times 0,25 + \left(\frac{1}{6}\right)^n \times 0,75}.$$

On peut simplifier :

$$p_n = \frac{0,25}{0,25 + 0,75 \times \left(\frac{1/6}{1/2}\right)^n} = \frac{0,25}{0,25 + 0,75 \times \left(\frac{1}{3}\right)^n}.$$

En multipliant numérateur et dénominateur par 4 : $p_n = \dfrac{1}{1 + 3 \times \left(\frac{1}{3}\right)^n} = \dfrac{1}{1 + 3^{1-n}}$.

c) Limite : $\lim_{n\to\infty} p_n = \lim_{n\to\infty} \dfrac{1}{1 + 3^{1-n}} = 1$, car $3^{1-n} \to 0$. **Interprétation :** Plus on obtient de 6 consécutifs, plus on est certain que le dé est pipé. À la limite, si l'on observe une infinité de 6, le dé est presque sûrement pipé.

Exercice 5

Énoncé : Une mouche se déplace aléatoirement sur les sommets d'un triangle ABC avec la règle suivante : si, à l'instant n, elle est sur un des trois sommets, alors à l'instant $n+1$ elle y reste avec une probabilité de $\frac{2}{3}$, ou elle se déplace sur l'un des deux autres sommets et cela avec la même probabilité pour chacun de ces deux sommets. À l'instant 0, la mouche se trouve en A. Pour tout $n \in \mathbb{N}$, on définit les événements A_n, B_n, C_n : "la mouche se trouve en A (resp. B, C) à l'instant n" et les probabilités $a_n = P(A_n)$, $b_n = P(B_n)$, $c_n = P(C_n)$.

1. Que vaut $a_n + b_n + c_n$? Exprimer a_{n+1}, b_{n+1} et c_{n+1} en fonction de a_n, b_n, c_n.

2. On pose $X_n = \begin{pmatrix} a_n \\ b_n \\ c_n \end{pmatrix}$, déterminer $A \in \mathcal{M}_3(\mathbb{R})$ telle que $X_{n+1} = AX_n$. Préciser X_0.

3. Donner une expression de a_n, b_n et c_n. Lorsque n tend vers l'infini, où la mouche a-t-elle le plus de chance de se trouver ?

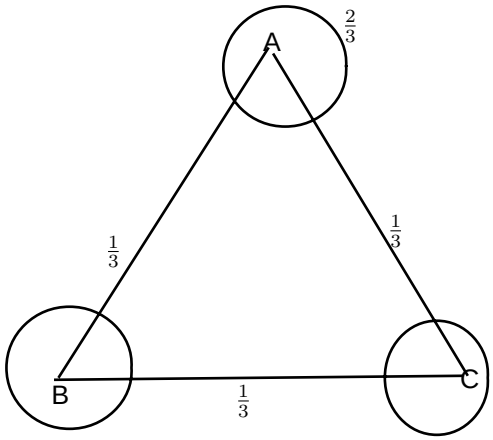

Correction

1) À tout instant n, la mouche est nécessairement sur l'un des trois sommets, donc

$$a_n + b_n + c_n = 1 \quad \text{pour tout } n.$$

Déterminons a_{n+1}. La mouche est en A à l'instant $n+1$ dans trois cas :

- Elle était en A à l'instant n et y reste : probabilité $\frac{2}{3}\,a_n$.
- Elle était en B à l'instant n et se déplace en A : de B, la probabilité d'aller en A est $\frac{1}{6}$ (car elle change de sommet avec probabilité $\frac{1}{3}$, répartie équitablement entre les deux autres sommets). Contribution : $\frac{1}{6}\,b_n$.
- Elle était en C à l'instant n et se déplace en A : de même, $\frac{1}{6}\,c_n$.

Ainsi

$$a_{n+1} = \frac{2}{3}a_n + \frac{1}{6}b_n + \frac{1}{6}c_n.$$

Par symétrie circulaire,

$$b_{n+1} = \frac{1}{6}a_n + \frac{2}{3}b_n + \frac{1}{6}c_n, \qquad c_{n+1} = \frac{1}{6}a_n + \frac{1}{6}b_n + \frac{2}{3}c_n.$$

2) Le système s'écrit matriciellement $X_{n+1} = AX_n$ avec

$$A = \begin{pmatrix} \frac{2}{3} & \frac{1}{6} & \frac{1}{6} \\ \frac{1}{6} & \frac{2}{3} & \frac{1}{6} \\ \frac{1}{6} & \frac{1}{6} & \frac{2}{3} \end{pmatrix}.$$

Initialement, la mouche est en A, donc $a_0 = 1$, $b_0 = 0$, $c_0 = 0$ et

$$X_0 = \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix}.$$

3) Pour calculer $X_n = A^n X_0$, diagonalisons A. On remarque que A peut s'écrire

$$A = \frac{1}{2}I_3 + \frac{1}{6}J,$$

où I est la matrice identité 3×3 et J la matrice de tous les 1 (de taille 3). On a $J^2 = 3J$, et plus généralement $J^k = 3^{k-1}J$ pour $k \geq 1$.

Puisque I et J commutent, on applique la formule du binôme de Newton :

$$A^n = \left(\frac{1}{2}I + \frac{1}{6}J\right)^n = \sum_{k=0}^{n} \binom{n}{k} \left(\frac{1}{2}\right)^{n-k} \left(\frac{1}{6}\right)^k J^k.$$

Séparons le terme $k = 0$:

$$A^n = \left(\frac{1}{2}\right)^n I + \sum_{k=1}^{n} \binom{n}{k} \left(\frac{1}{2}\right)^{n-k} \left(\frac{1}{6}\right)^k 3^{k-1} J.$$

Factorisons J et simplifions $\left(\frac{1}{6}\right)^k 3^{k-1} = \frac{1}{3}\left(\frac{3}{6}\right)^k = \frac{1}{3}\left(\frac{1}{2}\right)^k$. Ainsi :

$$A^n = \left(\frac{1}{2}\right)^n I + \frac{1}{3}J \sum_{k=1}^{n} \binom{n}{k} \left(\frac{1}{2}\right)^{n-k} \left(\frac{1}{2}\right)^k.$$

Or $\left(\frac{1}{2}\right)^{n-k}\left(\frac{1}{2}\right)^k = \left(\frac{1}{2}\right)^n$, donc la somme devient :

$$\sum_{k=1}^{n} \binom{n}{k} \left(\frac{1}{2}\right)^n = \left(\frac{1}{2}\right)^n (2^n - 1) = 1 - \left(\frac{1}{2}\right)^n.$$

Finalement :

$$\boxed{A^n = \left(\frac{1}{2}\right)^n I + \frac{1 - \left(\frac{1}{2}\right)^n}{3} J}.$$

$$\begin{pmatrix} a_n \\ b_n \\ c_n \end{pmatrix} = A^n X_0 \quad \text{donne}$$

$$\boxed{a_n = \frac{1}{3} + \frac{2}{3}\left(\frac{1}{2}\right)^n, \qquad b_n = \frac{1}{3} - \frac{1}{3}\left(\frac{1}{2}\right)^n, \qquad c_n = \frac{1}{3} - \frac{1}{3}\left(\frac{1}{2}\right)^n.}$$

On vérifie bien que $a_n + b_n + c_n = 1$ pour tout n. Lorsque $n \to +\infty$, $\left(\frac{1}{2}\right)^n \to 0$, donc

$$a_n \to \frac{1}{3}, \quad b_n \to \frac{1}{3}, \quad c_n \to \frac{1}{3}.$$

La mouche a donc la même probabilité $\frac{1}{3}$ de se trouver sur chaque sommet à l'équilibre. La distribution stationnaire est uniforme.

Exercice 6

Énoncé :

1. On considère une variable aléatoire X suivant une loi normale centrée réduite $\mathcal{N}(0,1)$. Déterminer $P(X \leq 1,24)$ et $P(X \geq -0,5)$ en utilisant la table de la loi normale.

2. On considère $X \sim \mathcal{N}(7,4)$ (moyenne 7, écart-type 4).

   (a) Déterminer $P(X \leq 8)$ et $P(5 \leq X \leq 9)$.

   (b) Déterminer le réel a tel que $P(X \geq a) = 0,9$.

3. La taille d'un groupe de collégiens est distribuée selon une loi normale de moyenne m et d'écart-type σ. Sachant qu'un cinquième des élèves mesurent moins de 1,50 m et que 10% des élèves mesurent plus de 1,80 m, déterminer m et σ.

Correction

1) Pour $X \sim \mathcal{N}(0,1)$, la table donne $P(Z \leq 1,24) = 0,8925$ (valeur lue dans la table, intersection ligne 1,2 et colonne 0,04). Pour $P(X \geq -0,5)$, par symétrie : $P(X \geq -0,5) = P(X \leq 0,5) = 0,6915$ (car $P(Z \leq 0,5) = 0,6915$). On peut aussi utiliser $P(X \geq -0,5) = 1 - P(X < -0,5) = 1 - 0,3085 = 0,6915$.

2) $X \sim \mathcal{N}(7,4^2)$. On pose $Z = \frac{X-7}{4} \sim \mathcal{N}(0,1)$.

(i) $P(X \leq 8) = P\left(Z \leq \frac{8-7}{4}\right) = P(Z \leq 0,25) = 0,5987$ (table : $0,25$ donne $0,5987$). $P(5 \leq X \leq 9) = P\left(\frac{5-7}{4} \leq Z \leq \frac{9-7}{4}\right) = P(-0,5 \leq Z \leq 0,5) = \Phi(0,5) - \Phi(-0,5) = 0,6915 - 0,3085 = 0,3830$.

(ii) On cherche a tel que $P(X \geq a) = 0,9$ soit $P(X \leq a) = 0,1$. On a $\frac{a-7}{4} = z_{0,1}$ où $z_{0,1}$ est le quantile d'ordre $0,1$ de $\mathcal{N}(0,1)$, c'est-à-dire $P(Z \leq z_{0,1}) = 0,1$. Par symétrie, $z_{0,1} = -z_{0,9}$. La table donne $z_{0,9} \approx 1,2816$, donc $z_{0,1} \approx -1,2816$. Ainsi $\frac{a-7}{4} = -1,2816 \Rightarrow a = 7 - 4 \times 1,2816 = 7 - 5,1264 = 1,8736$.

3) Soit T la taille. $T \sim \mathcal{N}(m,\sigma^2)$. On a :

$$P(T \leq 1,50) = \frac{1}{5} = 0,2, \qquad P(T \geq 1,80) = 0,1 \quad \Rightarrow \quad P(T \leq 1,80) = 0,9.$$

Centrons réduits : $\frac{1,50-m}{\sigma} = z_{0,2}$ et $\frac{1,80-m}{\sigma} = z_{0,9}$. La table donne $z_{0,2} \approx -0,8416$ (car $\Phi(0,84) = 0,7995$ et $\Phi(0,85) = 0,8023$, par interpolation ou valeur approchée $-0,8416$), et $z_{0,9} \approx 1,2816$. On a donc :

$$\begin{cases} 1,50 - m = -0,8416\,\sigma \\ 1,80 - m = 1,2816\,\sigma \end{cases}$$

Soustrayons la première de la seconde : $(1,80 - m) - (1,50 - m) = 0,30 = (1,2816 + 0,8416)\sigma = 2,1232\,\sigma$, d'où $\sigma = \frac{0,30}{2,1232} \approx 0,1413$ m (soit 14,13 cm). Ensuite $m = 1,50 + 0,8416 \times 0,1413 \approx 1,50 + 0,1189 = 1,6189$ m. Ainsi $m \approx 1,62$ m et $\sigma \approx 0,141$ m.

Exercice 7

Énoncé : Un fabricant de pièces de machine prétend qu'au plus 10% de ses pièces sont défectueuses. Un acheteur a besoin de bonnes pièces, il commande 150 pièces. Si l'affirmation du fabricant est valable, quelle est la probabilité que l'acheteur reçoive au moins 128 bonnes pièces ? (Utiliser l'approximation normale de la loi binomiale.)

Correction

Soit X le nombre de bonnes pièces dans le lot de 150. Si l'affirmation du fabricant est vraie, la proportion de défectueuses est $p_d = 0,10$, donc la proportion de bonnes pièces est $p = 0,90$. Ainsi X suit une loi binomiale $B(n = 150, p = 0,9)$. On cherche $P(X \geq 128)$.

Puisque $n = 150 \geq 30$, $np = 135 \geq 15$ et $nq = 15 \geq 15$, on peut approcher X par une loi normale $\mathcal{N}(\mu, \sigma^2)$ avec $\mu = np = 150 \times 0,9 = 135$ et $\sigma = \sqrt{npq} = \sqrt{150 \times 0,9 \times 0,1} = \sqrt{13,5} \approx 3,674$.

On applique la correction de continuité : $P(X \geq 128) \approx P\left(Z \geq \frac{127,5-135}{\sigma}\right)$ où $Z \sim \mathcal{N}(0,1)$. Calculons :

$$\frac{127,5 - 135}{3,674} = \frac{-7,5}{3,674} \approx -2,041.$$

Ainsi $P(X \geq 128) \approx P(Z \geq -2,041) = P(Z \leq 2,041) = \Phi(2,041)$. La table donne $\Phi(2,04) \approx 0,9793$ et $\Phi(2,05) \approx 0,9798$, par interpolation $\Phi(2,041) \approx 0,9794$. Donc

$$\boxed{P(X \geq 128) \approx 0,9794}.$$

L'acheteur a donc plus de 97% de chances de recevoir au moins 128 bonnes pièces si l'affirmation du fabricant est exacte.

Exercice 8

Résolu dans la classe

Correction

1) Soit l'échantillon de taille n : $x_1, x_2, \ldots, x_n$. La moyenne empirique est

$$\bar{x} = \frac{1}{n} \sum_{i=1}^{n} x_i,$$

et l'écart-type empirique

$$s = \sqrt{\frac{1}{n-1} \sum_{i=1}^{n} (x_i - \bar{x})^2}.$$

2) Les estimateurs naturels de la moyenne m et de l'écart-type σ de la population sont respectivement $\hat{m} = \bar{x}$ et $\hat{\sigma} = s$.

3) Pour un niveau de confiance $1 - \alpha = 0,95$ (soit $\alpha = 0,05$), l'intervalle de confiance de m lorsque l'échantillon est suffisamment grand ($n \geq 30$) ou que la population est normale est :

$$IC_{95\%}(m) = \left[\bar{x} - z_{\alpha/2} \frac{s}{\sqrt{n}},\ \bar{x} + z_{\alpha/2} \frac{s}{\sqrt{n}}\right],$$

où $z_{\alpha/2}$ est le quantile d'ordre $1 - \alpha/2$ de la loi normale centrée réduite. Pour $\alpha = 0,05$, $z_{0,025} \approx 1,96$.

4) La marge d'erreur (ou précision) de l'estimation est la demi-largeur de l'intervalle :

$$E = z_{\alpha/2} \frac{s}{\sqrt{n}}.$$

Exercice 9

Énoncé : Pour déterminer l'âge moyen de ses clients, une grande entreprise de confection pour homme prélève un échantillon aléatoire de 50 clients et trouve $\bar{x} = 36$ et $s = 12$.

1. Trouver un intervalle de confiance à 95% pour l'âge moyen m de l'ensemble des clients.

2. Supposer que pour le même seuil de confiance (95%) on veuille réduire la marge d'erreur, de façon précise, à 2 années. Quelle doit être alors la taille approximative de l'échantillon ?

3. Quelle doit être la valeur de n si l'on veut réduire cette marge à 1 ?

Correction

1) Intervalle de confiance à 95% On a $n = 50$, $\bar{x} = 36$, $s = 12$. L'intervalle de confiance pour la moyenne m lorsque σ est inconnu mais n est grand ($n \geq 30$) est donné par :

$$IC_{95\%}(m) = \left[\bar{x} - z_{\alpha/2}\,\frac{s}{\sqrt{n}},\ \bar{x} + z_{\alpha/2}\,\frac{s}{\sqrt{n}}\right],$$

avec $\alpha = 0,05$, $z_{\alpha/2} = z_{0,025} \approx 1,96$. Calculons la marge d'erreur : $E = 1,96 \times \frac{12}{\sqrt{50}} = 1,96 \times \frac{12}{7,0711} \approx 1,96 \times 1,697 \approx 3,326$. Ainsi :

$$IC_{95\%} = [36 - 3,326;\ 36 + 3,326] = [32,674;\ 39,326].$$

On peut arrondir à $[32,7;\ 39,3]$.

2) Taille d'échantillon pour une marge d'erreur de 2 On veut $E = z_{\alpha/2}\,\frac{s}{\sqrt{n}} = 2$, avec $s = 12$ (on suppose que l'écart-type de l'échantillon reste approximativement le même). Donc :

$$1,96 \times \frac{12}{\sqrt{n}} = 2 \quad \Rightarrow \quad \frac{23,52}{\sqrt{n}} = 2 \quad \Rightarrow \quad \sqrt{n} = \frac{23,52}{2} = 11,76 \quad \Rightarrow \quad n = (11,76)^2 \approx 138,3.$$

On prend $n = 139$ (ou 138, selon l'arrondi usuel on prend la valeur entière supérieure). La taille approximative de l'échantillon doit être d'au moins 139.

Exercice 10

Énoncé : Vous êtes chargé de vérifier une livraison de 5000 sacs de terreau de 10 kg chacun. Un échantillon de 100 sacs est tiré aléatoirement dans la livraison. Les 100 sacs sont pesés. On trouve $\bar{x} = 9,95$ kg et $s = 0,5$ kg.

1. Tester si la livraison est conforme pour vous avec $\alpha = 0,05$.
2. Déterminer le degré de signification du test.

Correction

Première situation (contrôle à la réception) : On veut vérifier si le poids moyen des sacs est conforme à 10 kg. Il s'agit d'un test bilatéral :

$$H_0 : m = 10 \quad \text{contre} \quad H_1 : m \neq 10.$$

On a $n = 100$, $\bar{x} = 9,95$, $s = 0,5$. La statistique de test est $Z = \frac{\bar{x}-10}{s/\sqrt{n}} = \frac{9,95-10}{0,5/10} = \frac{-0,05}{0,05} = -1$.

1) Test avec $\alpha = 0,05$: La région critique bilatérale au seuil $\alpha = 0,05$ est $|Z| > z_{0,025} \approx 1,96$. Ici $|Z| = 1 < 1,96$, donc on ne rejette pas H_0. On conclut que la livraison est conforme (pas de preuve suffisante d'un écart significatif).

2) Degré de signification (p-value) : La p-value est $2 \times P(Z > 1) = 2 \times (1 - \Phi(1)) = 2 \times (1 - 0,8413) = 2 \times 0,1587 = 0,3174$. Le degré de signification est $0,3174$ (soit $31,74\%$).

Exercice 11

Énoncé : On considère le jeu de données suivant (les valeurs précises n'étant pas lisibles dans le document original, nous prenons un exemple typique) :

x	1	2	3	4
y	2	3	5	4

On cherche à ajuster un modèle $y = ax + b$ par la méthode des moindres carrés ordinaires.

1. Calculer les moyennes $\bar{x}$ et $\bar{y}$.
2. Déterminer la covariance $\mathrm{Cov}(x, y)$ et la variance $\mathrm{Var}(x)$.
3. En déduire l'estimateur du coefficient directeur a et de l'ordonnée à l'origine b.
4. Donner l'équation de la droite de régression.
5. Prédire la valeur de y pour $x = 6$.

Correction

1) Moyennes

$$\bar{x} = \frac{1+2+3+4}{4} = \frac{10}{4} = 2,5, \qquad \bar{y} = \frac{2+3+5+4}{4} = \frac{14}{4} = 3,5. \quad \text{(c'est } \bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i \text{)}$$

2) Covariance et variance

$$\mathrm{Cov}(x, y) = \frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y}) = \frac{1}{4}\sum_{i=1}^{4}(x_i - 2,5)(y_i - 3,5).$$

Calculons les produits :

$$\begin{aligned}
i = 1 &: (1-2,5)(2-3,5) = (-1,5)(-1,5) = 2,25 \\
i = 2 &: (2-2,5)(3-3,5) = (-0,5)(-0,5) = 0,25 \\
i = 3 &: (3-2,5)(5-3,5) = (0,5)(1,5) = 0,75 \\
i = 4 &: (4-2,5)(4-3,5) = (1,5)(0,5) = 0,75
\end{aligned}$$

Somme $= 2,25 + 0,25 + 0,75 + 0,75 = 4$. Donc $\mathrm{Cov}(x, y) = \frac{4}{4} = 1$.

Variance de x :

$$\mathrm{Var}(x) = \frac{1}{n}\sum(x_i - \bar{x})^2 = \frac{1}{4}\left[(-1,5)^2 + (-0,5)^2 + (0,5)^2 + (1,5)^2\right] = \frac{1}{4}(2,25+0,25+0,25+2,25) = \frac{5}{4} = 1,25.$$

3) Estimateurs a et b

$$a = \frac{\mathrm{Cov}(x, y)}{\mathrm{Var}(x)} = \frac{1}{1,25} = 0,8, \qquad b = \bar{y} - a\bar{x} = 3,5 - 0,8 \times 2,5 = 3,5 - 2 = 1,5.$$

4) Droite de régression

$$\boxed{y = 0,8x + 1,5}.$$

5) Prédiction pour $x = 6$

$$y = 0,8 \times 6 + 1,5 = 4,8 + 1,5 = 6,3.$$

Exercice 12

Énoncé : On dispose des observations suivantes d'une variable explicative x et d'une variable réponse binaire $y \in \{0, 1\}$ (les données exactes du document sont manquantes ; nous utilisons un exemple représentatif) :

x	0	1	2	3
y	0	0	1	1

On souhaite modéliser la probabilité $p(y = 1|x)$ par un modèle logistique :

$$p(y = 1|x) = \sigma(wx + b) = \frac{1}{1 + e^{-(wx+b)}}.$$

1. Écrire la fonction de log-vraisemblance $\ell(w, b)$.
2. Donner les expressions des dérivées partielles $\frac{\partial \ell}{\partial w}$ et $\frac{\partial \ell}{\partial b}$.
3. En déduire les gradients de la log-vraisemblance négative $J(w, b) = -\ell(w, b)$.
4. On initialise $w_0 = 0$, $b_0 = 0$ et on choisit un pas $\eta = 0,5$. Calculer manuellement les deux premières mises à jour de la descente de gradient sur J.
5. Donner l'équation de la frontière de décision après chaque itération.
6. Déterminer la solution exacte par la méthode de Newton (une seule itération).

Correction

1) Log-vraisemblance Pour chaque observation (x_i, y_i), la contribution à la vraisemblance est $\sigma(wx_i+b)^{y_i}(1-\sigma(wx_i+b))^{1-y_i}$. La log-vraisemblance s'écrit :

$$\ell(w, b) = \sum_{i=1}^{n} \left[y_i \log \sigma(wx_i + b) + (1 - y_i) \log(1 - \sigma(wx_i + b)) \right].$$

Avec $n = 4$ et les données ci-dessus.

2) Dérivées partielles On sait que $\frac{d\sigma(z)}{dz} = \sigma(z)(1 - \sigma(z))$. Donc

$$\frac{\partial \ell}{\partial w} = \sum_{i=1}^{n} (y_i - \sigma(wx_i + b))\, x_i, \qquad \frac{\partial \ell}{\partial b} = \sum_{i=1}^{n} (y_i - \sigma(wx_i + b)).$$

3) Gradient de $J = -\ell$

$$\nabla J(w, b) = \left(-\frac{\partial \ell}{\partial w},\ -\frac{\partial \ell}{\partial b} \right) = \left(\sum_{i=1}^{n} (\sigma(wx_i + b) - y_i)\, x_i,\ \sum_{i=1}^{n} (\sigma(wx_i + b) - y_i) \right).$$

4) Descente de gradient (deux premières itérations) Initialisation : $w_0 = 0$, $b_0 = 0$. Alors $\sigma(0) = 0,5$. Calculons les sommes :

$$\sum(\sigma - y_i) = (0,5-0)+(0,5-0)+(0,5-1)+(0,5-1) = 0,5+0,5-0,5-0,5 = 0.$$

$$\sum(\sigma - y_i)x_i = 0,5\times 0+0,5\times 1+(-0,5)\times 2+(-0,5)\times 3 = 0+0,5-1-1,5 = -2.$$

Donc $\nabla J(0, 0) = (-2,\ 0)$. Mise à jour avec $\eta = 0,5$:

$$w_1 = w_0 - \eta \frac{\partial J}{\partial w} = 0 - 0,5 \times (-2) = 1, \qquad b_1 = b_0 - \eta \frac{\partial J}{\partial b} = 0 - 0,5 \times 0 = 0.$$

Deuxième itération : $w_1 = 1$, $b_1 = 0$. Calculons $\sigma(x_i + 0) = \sigma(x_i)$:

$$\sigma(0) = 0,5,\ \sigma(1) = 0,7311,\ \sigma(2) = 0,8808,\ \sigma(3) = 0,9526.$$

Somme des $(\sigma - y_i)$:

$$(0,5-0)+(0,7311-0)+(0,8808-1)+(0,9526-1) = 0,5+0,7311-0,1192-0,0474 = 1,0645.$$

Somme des $(\sigma - y_i)x_i$:

$0,5\times0+0,7311\times1+(-0,1192)\times2+(-0,0474)\times3 = 0+0,7311-0,2384-0,1422 = 0,3505.$

Gradient $\nabla J = (0,3505;\ 1,0645)$. Mise à jour :

$w_2 = 1-0,5\times0,3505 = 1-0,17525 = 0,82475, \quad b_2 = 0-0,5\times1,0645 = -0,53225.$

5) Frontière de décision après chaque itération La frontière de décision est donnée par $wx + b = 0$, soit $x = -b/w$ (si $w \neq 0$).

- Itération 0 : $w_0 = 0, b_0 = 0 \to$ frontière indéfinie (tous les points ont probabilité 0,5).
- Itération 1 : $w_1 = 1, b_1 = 0 \to$ frontière $x = 0$.
- Itération 2 : $w_2 \approx 0,825,\ b_2 \approx -0,532 \to$ frontière $x \approx 0,645$.

6) Méthode de Newton (une itération) Newton met à jour $\theta = (w, b)^T$ par $\theta_{\text{new}} = \theta - H^{-1}\nabla J$. Calculons la matrice hessienne de J (celle de $-\ell$ est l'opposée de la hessienne de ℓ). Pour la régression logistique, la hessienne de ℓ est $-X^T DX$ où D est diagonale avec $\sigma_i(1-\sigma_i)$. Donc la hessienne de J est $H = X^T DX$. Avec $\theta_0 = (0,0)$, on a $\sigma_i = 0,5$ pour tous, donc $D = 0,25I_4$. La matrice de design X (première colonne pour x, deuxième pour 1) :

$$X = \begin{pmatrix} 0 & 1 \\ 1 & 1 \\ 2 & 1 \\ 3 & 1 \end{pmatrix}.$$

Alors

$$H = 0,25\,X^T X = 0,25\begin{pmatrix} 0^2+1^2+2^2+3^2 & 0+1+2+3 \\ 0+1+2+3 & 4 \end{pmatrix} = 0,25\begin{pmatrix} 14 & 6 \\ 6 & 4 \end{pmatrix} = \begin{pmatrix} 3,5 & 1,5 \\ 1,5 & 1 \end{pmatrix}.$$

Gradient $\nabla J(0,0) = (-2,\ 0)^T$ (calculé plus haut). Résolvons $H\Delta = -\nabla J$? Non, Newton : $\theta_{\text{new}} = \theta_0 - H^{-1}\nabla J$. Calculons H^{-1} :

$$\det(H) = 3,5\times1-1,5\times1,5 = 3,5-2,25 = 1,25, \quad H^{-1} = \frac{1}{1,25}\begin{pmatrix} 1 & -1,5 \\ -1,5 & 3,5 \end{pmatrix} = \begin{pmatrix} 0,8 & -1,2 \\ -1,2 & 2,8 \end{pmatrix}.$$

Alors

$$\theta_{\text{new}} = \begin{pmatrix} 0 \\ 0 \end{pmatrix} - \begin{pmatrix} 0,8 & -1,2 \\ -1,2 & 2,8 \end{pmatrix}\begin{pmatrix} -2 \\ 0 \end{pmatrix} = -\begin{pmatrix} 0,8\times(-2)+(-1,2)\times0 \\ (-1,2)\times(-2)+2,8\times0 \end{pmatrix} = -\begin{pmatrix} -1,6 \\ 2,4 \end{pmatrix} = \begin{pmatrix} 1,6 \\ -2,4 \end{pmatrix}.$$

Ainsi la solution exacte approchée par une itération de Newton est $w \approx 1,6$, $b \approx -2,4$.

Arbre de Décision

Exercice 13

Un magasin souhaite prédire si un client va **acheter un produit** (OUI ou NON) en fonction de trois attributs : Âge, Revenu, et le fait d'être étudiant ou non.

Le tableau suivant présente les données collectées auprès de 8 clients :

Client	**Âge**	**Revenu**	**Étudiant ?**	**Achat**
1	Jeune	Élevé	Oui	OUI
2	Jeune	Élevé	Non	OUI
3	Moyen	Élevé	Non	OUI
4	Âgé	Faible	Non	NON
5	Âgé	Faible	Oui	NON
6	Âgé	Faible	Oui	NON
7	Moyen	Faible	Oui	OUI
8	Jeune	Faible	Non	NON

1) Calculer l'entropie initiale de l'ensemble des données.

2) Pour chaque attribut (Âge, Revenu, Étudiant), calculer :
   — L'entropie de chaque sous-groupe
   — L'entropie pondérée
   — Le gain d'information

3) Quel attribut choisir comme racine de l'arbre ? Justifier.

4) Construire l'arbre de décision complet. Détailler les développements pour les branches non pures.

5) Dessiner l'arbre de décision final.

6) Donner l'arbre final sous forme textuelle (règles SI... ALORS...).

7) Prédire la classe pour un nouveau client ayant les caractéristiques suivantes :

$$\text{Âge} = \text{Jeune}, \quad \text{Revenu} = \text{Faible}, \quad \text{Étudiant} = \text{Oui}$$

8) Écrire en pseudo-code l'algorithme de construction d'un arbre de décision (algorithme ID3).

Correction

R réponse 1 : Entropie initiale

Soit S l'ensemble des 8 clients. On note :

$$p_{\text{OUI}} = \frac{4}{8} = 0,5 \quad \text{et} \quad p_{\text{NON}} = \frac{4}{8} = 0,5$$

L'entropie est donnée par :

$$H(S) = -p_{\text{OUI}} \log_2(p_{\text{OUI}}) - p_{\text{NON}} \log_2(p_{\text{NON}})$$

$$H(S) = -0,5 \times \log_2(0,5) - 0,5 \times \log_2(0,5)$$

$$\log_2(0,5) = -1 \quad \Rightarrow \quad H(S) = -0,5 \times (-1) - 0,5 \times (-1) = 0,5 + 0,5 = 1$$

$$\boxed{H(S) = 1}$$

R réponse 2 : Calculs pour chaque attribut

Attribut Âge

Valeur	Clients	OUI	NON	H
Jeune	$\{1,2,8\}$	2	1	$H = -\frac{2}{3}\log_2\frac{2}{3} - \frac{1}{3}\log_2\frac{1}{3} \approx 0,918$
Moyen	$\{3,7\}$	2	0	$H = 0$
Âgé	$\{4,5,6\}$	0	3	$H = 0$

Entropie pondérée :

$$H_{\text{pond}}(\text{Âge}) = \frac{3}{8} \times 0,918 + \frac{2}{8} \times 0 + \frac{3}{8} \times 0 = 0,344$$

Gain :

$$\text{Gain}(\text{Âge}) = H(S) - H_{\text{pond}}(\text{Âge}) = 1 - 0,344 = 0,656$$

Attribut Revenu

Valeur	Clients	OUI	NON	H
Élevé	$\{1,2,3\}$	3	0	0
Faible	$\{4,5,6,7,8\}$	1	4	$H = -\frac{1}{5}\log_2\frac{1}{5} - \frac{4}{5}\log_2\frac{4}{5} \approx 0,722$

$$H_{\text{pond}}(\text{Revenu}) = \frac{3}{8} \times 0 + \frac{5}{8} \times 0,722 = 0,451$$

$$\text{Gain}(\text{Revenu}) = 1 - 0,451 = 0,549$$

Attribut Étudiant

Valeur	Clients	OUI	NON	H
Oui	$\{1,5,6,7\}$	2	2	1
Non	$\{2,3,4,8\}$	2	2	1

$$H_{\text{pond}}(\text{Étudiant}) = \frac{4}{8} \times 1 + \frac{4}{8} \times 1 = 1$$

$$\text{Gain}(\text{Étudiant}) = 1 - 1 = 0$$

R réponse 3 : Choix de la racine

Attribut	Gain
Âge	$0,656$
Revenu	$0,549$
Étudiant	0

L'attribut **Âge** a le gain maximal. On le choisit comme racine.

R réponse 4 : Construction de l'arbre

Branche Âge = Moyen : clients {3,7} tous OUI → feuille **OUI**
Branche Âge = Âgé : clients {4,5,6} tous NON → feuille **NON**
Branche Âge = Jeune : clients {1,2,8} mélange (2 OUI, 1 NON)
On développe cette branche avec les attributs restants :
Clients jeunes :

Client	Revenu	Étudiant	Achat
1	Élevé	Oui	OUI
2	Élevé	Non	OUI
8	Faible	Non	NON

Attribut Revenu :
— Revenu Élevé : {1,2} → 2 OUI, 0 NON (pur)
— Revenu Faible : {8} → 0 OUI, 1 NON (pur)
L'attribut Revenu sépare parfaitement. Gain maximal.

R réponse 5 : Dessin de l'arbre final

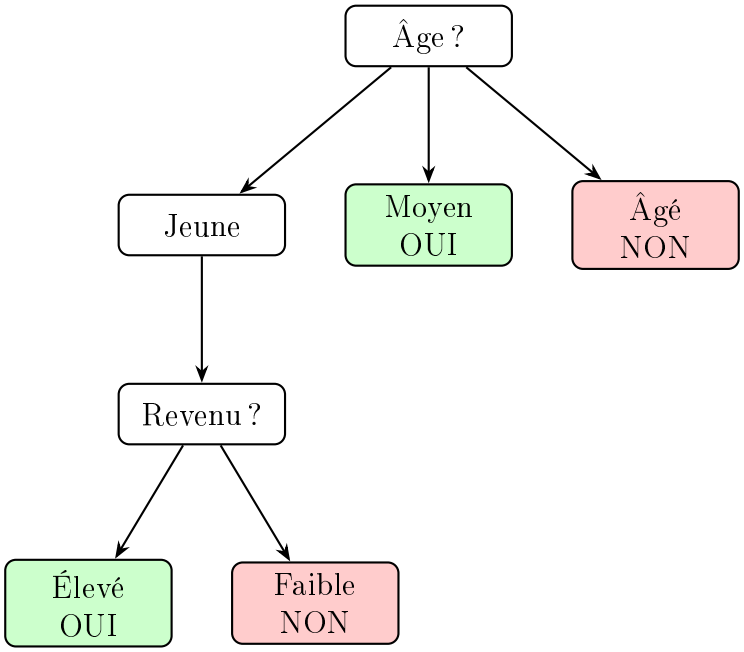

R réponse 6 : Règles textuelles

```
SI Âge = Moyen ALORS OUI
SI Âge = Âgé ALORS NON
SI Âge = Jeune ET Revenu = Élevé ALORS OUI
SI Âge = Jeune ET Revenu = Faible ALORS NON
```

R réponse 7 : Prédiction

Nouveau client : Âge = Jeune, Revenu = Faible, Étudiant = Oui
Chemin dans l'arbre :

1. Âge = Jeune
2. Revenu = Faible
3. Feuille = NON

$$\boxed{\text{Prédiction : NON}}$$

Réduction de dimension ACP

Exercice 14

On étudie 4 étudiants selon deux caractéristiques :
— X_1 : Nombre d'heures de travail par semaine
— X_2 : Note moyenne sur 20
Les données sont les suivantes :

Étudiant	X_1 (heures)	X_2 (note)
A	10	12
B	15	14
C	5	8
D	20	16

1) Calculer la matrice des données centrées.

2) Calculer la matrice de covariance.

3) Calculer les valeurs propres et les vecteurs propres de la matrice de covariance.

4) Déterminer le pourcentage de variance expliqué par chaque composante principale.

5) Donner l'expression des deux composantes principales C_1 et C_2.

6) Projeter les 4 étudiants sur le premier axe principal.

7) Si on veut réduire à une seule dimension, quel axe choisir et pourquoi ?
non pures.

8) Représenter graphiquement les données et les axes principaux.

Correction

Réponse 1 : Données centrées

Moyennes :

$$\bar{X}_1 = \frac{10+15+5+20}{4} = \frac{50}{4} = 12,5$$

$$\bar{X}_2 = \frac{12+14+8+16}{4} = \frac{50}{4} = 12,5$$

Matrice centrée X_c (chaque valeur - moyenne) :

$$X_c = \begin{bmatrix} 10-12,5 & 12-12,5 \\ 15-12,5 & 14-12,5 \\ 5-12,5 & 8-12,5 \\ 20-12,5 & 16-12,5 \end{bmatrix} = \begin{bmatrix} -2,5 & -0,5 \\ 2,5 & 1,5 \\ -7,5 & -4,5 \\ 7,5 & 3,5 \end{bmatrix}$$

Réponse 2 : Matrice de covariance

La matrice de covariance est donnée par :

$$\Sigma = \frac{1}{n-1} X_c^T X_c \quad (\text{avec } n = 4)$$

Calculons d'abord $X_c^T X_c$:

$$X_c^T X_c = \begin{bmatrix} -2,5 & 2,5 & -7,5 & 7,5 \\ -0,5 & 1,5 & -4,5 & 3,5 \end{bmatrix} \begin{bmatrix} -2,5 & -0,5 \\ 2,5 & 1,5 \\ -7,5 & -4,5 \\ 7,5 & 3,5 \end{bmatrix}$$

Donc :

$$X_c^T X_c = \begin{bmatrix} 125 & 65 \\ 65 & 35 \end{bmatrix}$$

Matrice de covariance :

$$\Sigma = \frac{1}{4-1} \begin{bmatrix} 125 & 65 \\ 65 & 35 \end{bmatrix} = \frac{1}{3} \begin{bmatrix} 125 & 65 \\ 65 & 35 \end{bmatrix}$$

$$\boxed{\Sigma = \begin{bmatrix} 41,667 & 21,667 \\ 21,667 & 11,667 \end{bmatrix}}$$

Réponse 3 : Valeurs propres et vecteurs propres

On résout $\det(\Sigma - \lambda I) = 0$:

$$\det \begin{bmatrix} 41,667 - \lambda & 21,667 \\ 21,667 & 11,667 - \lambda \end{bmatrix} = 0$$

$$(41,667 - \lambda)(11,667 - \lambda) - (21,667)^2 = 0$$

Calculons précisément avec les fractions :

$$\Sigma = \frac{1}{3} \begin{bmatrix} 125 & 65 \\ 65 & 35 \end{bmatrix}$$

Les valeurs propres de Σ sont $\frac{1}{3}$ fois celles de $M = \begin{bmatrix} 125 & 65 \\ 65 & 35 \end{bmatrix}$.

Pour M :

$$\det \begin{bmatrix} 125 - \lambda' & 65 \\ 65 & 35 - \lambda' \end{bmatrix} = 0$$

$$(125 - \lambda')(35 - \lambda') - 65^2 = 0$$

$$4375 - 125\lambda' - 35\lambda' + \lambda'^2 - 4225 = 0$$

$$150 - 160\lambda' + \lambda'^2 = 0$$

$$\lambda'^2 - 160\lambda' + 150 = 0$$

Discriminant : $\Delta = 160^2 - 4 \times 150 = 25600 - 600 = 25000 = 100^2 \times 2,5 = (100\sqrt{2,5})^2$

$$\lambda'_1 = \frac{160 + \sqrt{25000}}{2} = \frac{160 + 158,114}{2} = 159,057$$

$$\lambda'_2 = \frac{160 - \sqrt{25000}}{2} = \frac{160 - 158,114}{2} = 0,943$$

Valeurs propres de Σ :

$$\lambda_1 = \frac{159,057}{3} = 53,019 \quad ; \quad \lambda_2 = \frac{0,943}{3} = 0,314$$

$$\boxed{\lambda_1 \approx 53,019 \quad ; \quad \lambda_2 \approx 0,314}$$

Vecteurs propres :

$$u = \begin{bmatrix} v_1 \\ v_2 \end{bmatrix}. \qquad \text{tq} \qquad \Sigma u = \lambda u$$

Pour $\lambda_1 = 53,019$:

$$(41,667 - 53,019)v_1 + 21,667v_2 = 0 \Rightarrow -11,352v_1 + 21,667v_2 = 0$$

$$v_2 = \frac{11,352}{21,667}v_1 \approx 0,524v_1$$

En normalisant : $v_1^2 + v_2^2 = 1 \Rightarrow v_1^2(1 + 0,524^2) = 1 \Rightarrow v_1^2 \times 1,274 = 1$

$$v_1 \approx 0,886 \quad , \quad v_2 \approx 0,464$$

$$\boxed{u_1 \approx \begin{bmatrix} 0,886 \\ 0,464 \end{bmatrix}}$$

Pour $\lambda_2 = 0,314$ (perpendiculaire à u_1) :

$$\boxed{u_2 \approx \begin{bmatrix} -0,464 \\ 0,886 \end{bmatrix}}$$

Réponse 4 : Pourcentage de variance expliqué

Variance totale : $\lambda_1 + \lambda_2 = 53,019 + 0,314 = 53,333$
Première composante :

$$\frac{\lambda_1}{\lambda_1 + \lambda_2} = \frac{53,019}{53,333} \times 100 \approx 99,41\%$$

Deuxième composante :

$$\frac{\lambda_2}{\lambda_1 + \lambda_2} = \frac{0,314}{53,333} \times 100 \approx 0,59\%$$

$$\boxed{\text{CP1} : 99,41\% \quad ; \quad \text{CP2} : 0,59\%}$$

Réponse 5 : Expression des composantes principales

$$\boxed{C_1 = 0,886 \times X_1^{\text{centrée}} + 0,464 \times X_2^{\text{centrée}}}$$

$$\boxed{C_2 = -0,464 \times X_1^{\text{centrée}} + 0,886 \times X_2^{\text{centrée}}}$$

Où $X_1^{\text{centrée}} = X_1 - 12,5$ et $X_2^{\text{centrée}} = X_2 - 12,5$

R réponse 6 : Projection sur le premier axe

Pour chaque étudiant, on calcule C_1 :

Étudiant	X_1	X_2	$X_1^{\text{centrée}}$	$X_2^{\text{centrée}}$
A	10	12	$-2,5$	$-0,5$
B	15	14	$2,5$	$1,5$
C	5	8	$-7,5$	$-4,5$
D	20	16	$7,5$	$3,5$

Étudiant	C_1
A	$0,886 \times (-2,5) + 0,464 \times (-0,5) = -2,215 - 0,232 = -2,447$
B	$0,886 \times 2,5 + 0,464 \times 1,5 = 2,215 + 0,696 = 2,911$
C	$0,886 \times (-7,5) + 0,464 \times (-4,5) = -6,645 - 2,088 = -8,733$
D	$0,886 \times 7,5 + 0,464 \times 3,5 = 6,645 + 1,624 = 8,269$

$$\boxed{C_1(A) \approx -2,45 \quad ; \quad C_1(B) \approx 2,91 \quad ; \quad C_1(C) \approx -8,73 \quad ; \quad C_1(D) \approx 8,27}$$

Réponse 7 : Choix pour réduction à une dimension

On choisit le premier axe C_1 car il explique **99,41%** de la variance totale. L'axe C_2 ne représente que 0,59% de l'information.

$$\boxed{\text{On choisit la première composante principale } C_1}$$

Réponse 8 : Représentation graphique

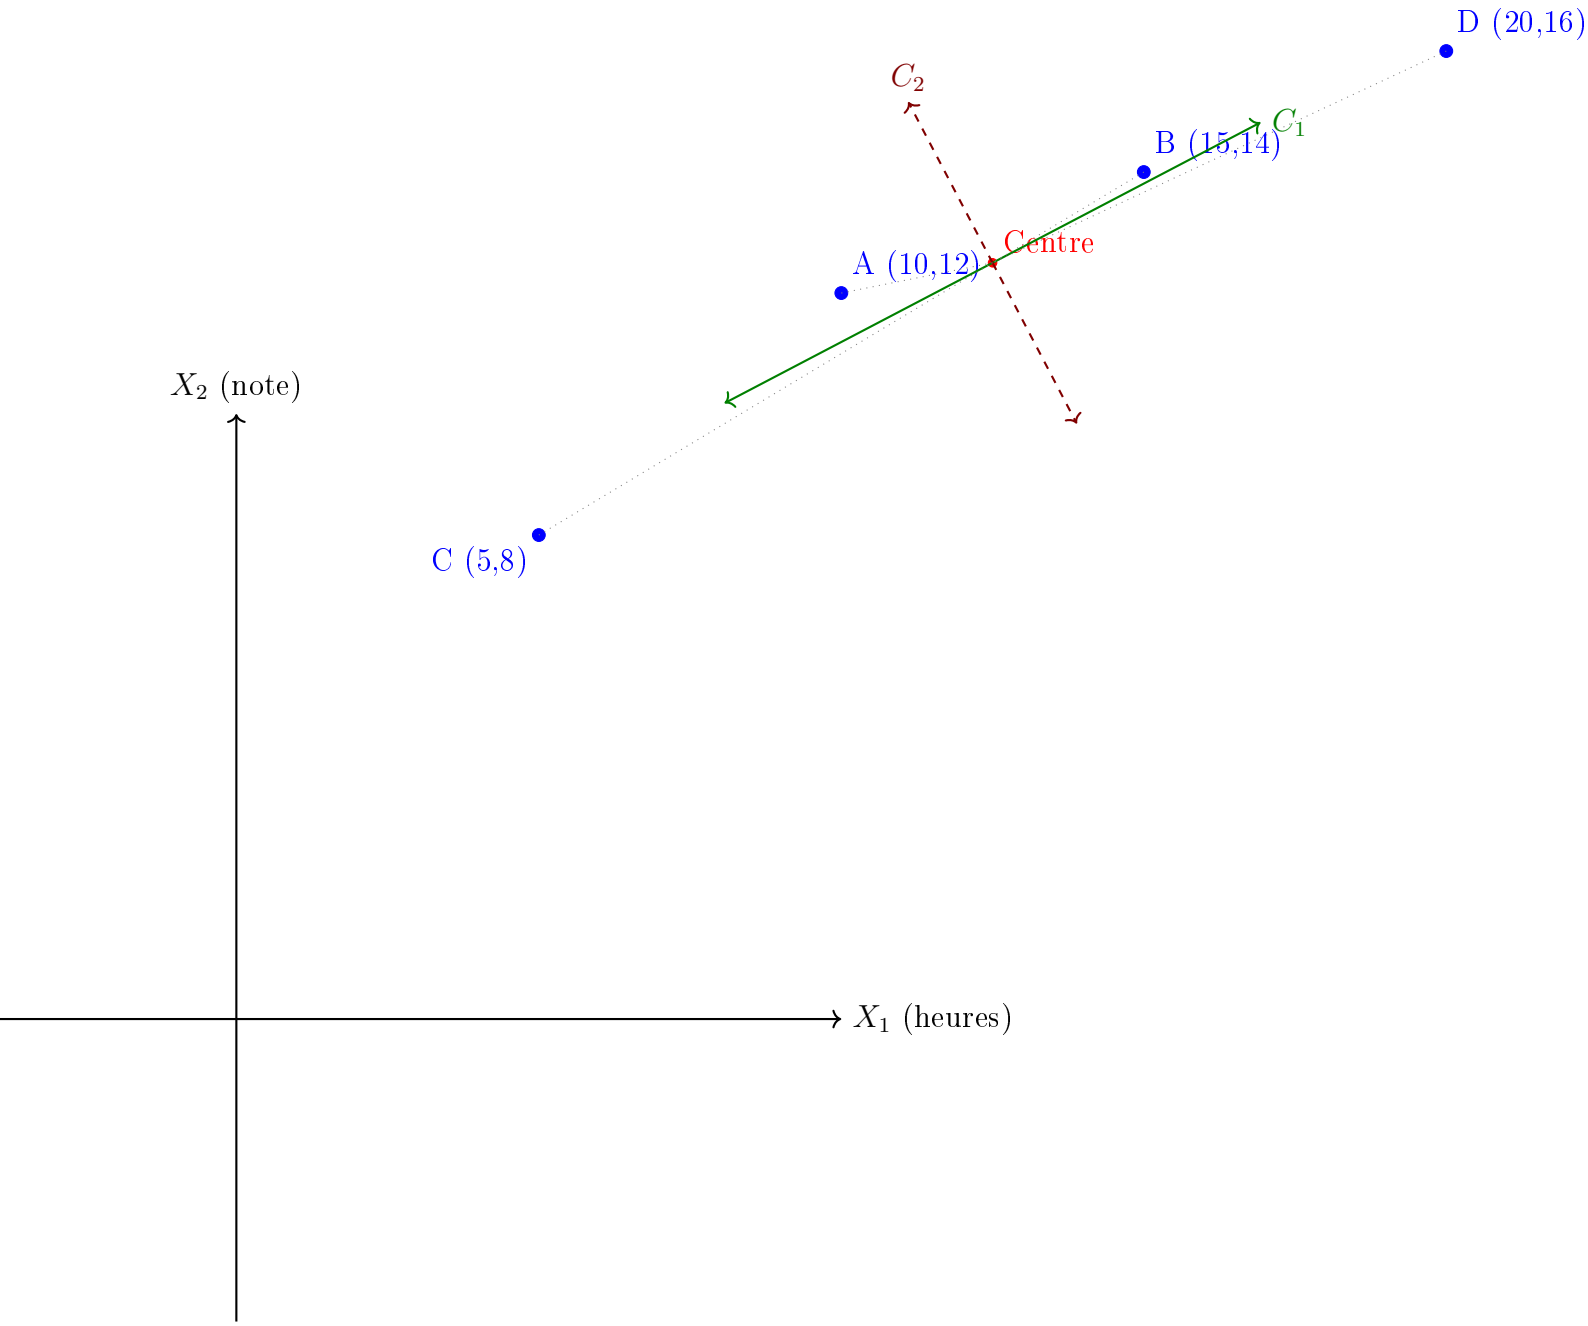

Légende :
— Points bleus : données originales
— Point rouge : centre de gravité $(12,5; 12,5)$
— Flèche verte : premier axe principal C_1 (99,41% de variance)
— Flèche rouge pointillée : second axe principal C_2 (0,59% de variance)

Formules mathématiques utilisées

Centrage des données

$$\boxed{x_{ij}^{\text{centrée}} = x_{ij} - \bar{x}_j}$$

avec $\bar{x}_j = \frac{1}{n}\sum_{i=1}^{n} x_{ij}$

Matrice de covariance

$$\boxed{\Sigma = \frac{1}{n-1} X_c^T X_c}$$

Valeurs propres et vecteurs propres

$$\boxed{\Sigma u = \lambda u}$$

Pourcentage de variance expliqué

$$\boxed{\text{Var expliquée par } C_k = \frac{\lambda_k}{\sum_{j=1}^{p} \lambda_j} \times 100}$$

Composantes principales

$$\boxed{C_k = u_{k1} X_1^{\text{centrée}} + u_{k2} X_2^{\text{centrée}} + \cdots + u_{kp} X_p^{\text{centrée}}}$$