TD: Statistiques et optimisation pour ML

Exercice 1 *Le fonctionnement d'un appareil est régi par la règle suivante :*

- *s'il fonctionne à l'instant t_n alors il a la probabilité $a \in]0;1[$ de fonctionner à l'instant t_{n+1} ;*
- *s'il est en panne à l'instant t_n alors il a la probabilité $b \in]0;1[$ d'être en panne à l'instant t_{n+1}.*

Il est en état de marche à l'instant 0. *Déterminer la probabilité p_n qu'il soit en état de marche à l'instant t_n.*

Indication : Exprimer p_{n+1} en fonction de p_n puis determiner l'expression de p_n

Exercice 2

Soit N un entier strictement positif, et p un réel strictement compris entre 0 et 1.

Une particule se déplace sur une droite en faisant des sauts d'une unité vers la gauche ou vers la droite. A chaque instant, la probabilité qu'elle aille vers la droite est p et celle qu'elle aille vers la gauche $q = 1 - p$, tous ces déplacements étant supposés indépendants.

Initialement, la particule est en $n \in [\![0, N]\!]$, et elle s'arrête dès qu'elle atteint l'une des extrémités de cet intervalle : 0 ou N.

On note q_n la probabilité que la particule s'arrête en 0.

1) a) Justifier que $q_0 = 1$ et $q_N = 0$.

b) Montrer que pour tout n tel que $1 \leqslant n \leqslant N - 1$, on a

$$q_n = pq_{n+1} + qq_{n-1}$$

c) En déduire une expression de q_n en fonction de n, N, p et q.
On pensera à distinguer les cas $p = 1/2$ et $p \neq 1/2$.

2) Calculer de même la probabilité p_n que la particule s'arrête en N (mêmes cas).

3) Calculer $p_n + q_n$, et en déduire la probabilité pour que la particule ne s'arrête jamais.

Exercice 3

Dans une population, une personne sur 10 000 souffre d'une pathologie. Un laboratoire pharmaceutique met sur le marché un test sanguin. Celui-ci est positif chez 99 % des malades mais aussi faussement positif chez 0,1 % des personnes non atteintes. Un individu passe ce test et obtient un résultat positif.

Quelle est sa probabilité d'être malade ? Qu'en conclure ?

Exercice 4

1) Enoncer et démontrer la formule de Bayes.

2) On dispose de 100 dés dont 25 sont pipés.
Pour chaque dé pipé, la probabilité d'obtenir le chiffre 6 lors d'un lancer vaut $\frac{1}{2}$.

a) On tire un dé au hasard parmi les 100 dés. On lance ce dé et on obtient le chiffre 6.
Quelle est la probabilité que ce dé soit pipé ?

b) Soit $n \in \mathbb{N}^*$.
On tire un dé au hasard parmi les 100 dés. On lance ce dé n fois et on obtient n fois le chiffre 6.
Quelle est la probabilité p_n que ce dé soit pipé ?

c) Déterminer $\lim\limits_{n \to +\infty} p_n$. Interpréter ce résultat.

Exercice 5 *Une mouche se déplace aléatoirement sur les sommets d'un triangle ABC avec la règle suivante : si, à l'instant n, elle est sur un des trois sommets, alors à l'instant $n+1$ elle y reste avec une probabilité de $\frac{2}{3}$, ou elle se déplace sur l'un des deux autres sommets et cela avec la même probabilité pour chacun de ces deux sommets.*
A l'instant 0, la mouche se trouve en A. Pour tout $n \in \mathbb{N}$, on définit les événements A_n (respectivement B_n et C_n) :

" la mouche se trouve en A (respectivement B et C) à l'instant n "

et les probabiliés $a_n = p(A_n)$, $b_n = p(B_n)$ et $c_n = p(C_n)$.

1. *Que vaut $a_n + b_n + c_n$? Exprimer a_{n+1}, b_{n+1} et c_{n+1} en fonction de a_n, b_n et c_n.*
2. *On pose $X_n = \begin{pmatrix} a_n \\ b_n \\ c_n \end{pmatrix}$, déterminer $A \in \mathcal{M}_3(\mathbb{R})$ telle que $X_{n+1} = AX_n$. Préciser X_0.*
3. *Donner une expression de a_n, b_n et c_n. Lorsque n tend vers l'infini, où la mouche a-t-elle le plus de chance de se trouver ?*

Variables aléatoires

Exercice 6 : 1. *On considère une variable aléatoire X suivant une loi normale centrée réduite. Déterminer $P(X \leq 1{,}13)$ et $P(X \geq 2{,}45)$.*

2. *On considère une variable aléatoire X suivant une loi normale de moyenne 7 et d'écart-type 4. (i)Déterminer $P(X \leq 8)$ et $P(5 \leq X \leq 9)$, (ii) déterminer le réel a tel que $P(X \geq a) = 0,9$.*

3. *La taille d'un groupe de collégiens est distribuée selon une loi normale de moyenne m et d'écart-type σ. Sachant qu'un cinquième des élèves mesurent moins de 1m50 et que 10% des élèves mesurent plus de 1m80. Déterminer m et σ.*

Exercice 7 :

Un fabricant de pièces de machine prétend qu'au plus 10% de ses pièces sont défectueuses. Un acheteur a besoin 128 *depièces. Pour disposer d'un nombre suffisant de bonnes pièces, il en commande* 150. *Si l'affirmation du fabricant est valable, quelle est la probabilité que l'acheteur reçoive au moins 120 bonnes pièces ?*

Indication: On peut effectuer l'approximation d'une loi binomiale $B(n,p)$ par la loi $\mathcal{N}(np, \sqrt{npq})$ dès que $n \geq 30, np \geq 15$ et $nq \geq 15$

TABLE DE LA LOI NORMALE CENTREE REDUITE

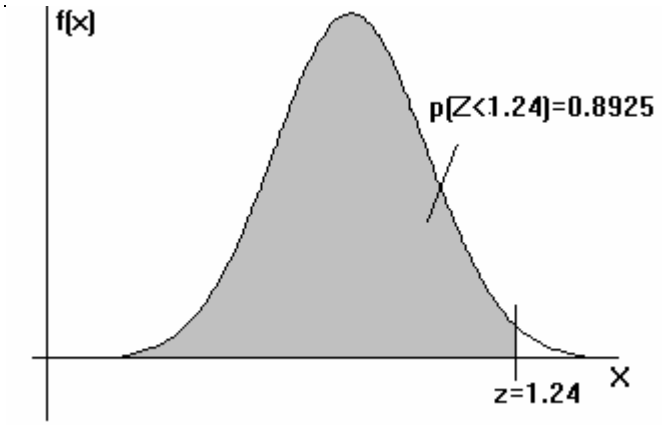

Rappels:

1/ $P(Z > z) = 1 - P(Z < z)$ et 2/ $P(Z > z) = P(Z < -z)$

Exemple: Sachant $P(Z < 1{,}24) = 0{,}8925$, on en déduit:

1/ $(P(Z > 1{,}24) = 1 - P(Z < 1{,}24) = 1 - 0{,}8925 = 0{,}1075$

2/ $P(Z < -1{,}24) = P(Z > 1{,}24) = 0{,}1075$

z	0,00	0,01	0,02	0,03	0,04	0,05	0,06	0,07	0,08	0,09
0,0	0,5000	0,5040	0,5080	0,5120	0,5160	0,5199	0,5239	0,5279	0,5319	0,5359
0,1	0,5398	0,5438	0,5478	0,5517	0,5557	0,5596	0,5636	0,5675	0,5714	0,5753
0,2	0,5793	0,5832	0,5871	0,5910	0,5948	0,5987	0,6026	0,6064	0,6103	0,6141
0,3	0,6179	0,6217	0,6255	0,6293	0,6331	0,6368	0,6406	0,6443	0,6480	0,6517
0,4	0,6554	0,6591	0,6628	0,6664	0,6700	0,6736	0,6772	0,6808	0,6844	0,6879
0,5	0,6915	0,6950	0,6985	0,7019	0,7054	0,7088	0,7123	0,7157	0,7190	0,7224
0,6	0,7257	0,7291	0,7324	0,7357	0,7389	0,7422	0,7454	0,7486	0,7517	0,7549
0,7	0,7580	0,7611	0,7642	0,7673	0,7704	0,7734	0,7764	0,7794	0,7823	0,7852
0,8	0,7881	0,7910	0,7939	0,7967	0,7995	0,8023	0,8051	0,8078	0,8106	0,8133
0,9	0,8159	0,8186	0,8212	0,8238	0,8264	0,8289	0,8315	0,8340	0,8365	0,8389
1,0	0,8413	0,8438	0,8461	0,8485	0,8508	0,8531	0,8554	0,8577	0,8599	0,8621
1,1	0,8643	0,8665	0,8686	0,8708	0,8729	0,8749	0,8770	0,8790	0,8810	0,8830
1,2	0,8849	0,8869	0,8888	0,8907	0,8925	0,8944	0,8962	0,8980	0,8997	0,9015
1,3	0,9032	0,9049	0,9066	0,9082	0,9099	0,9115	0,9131	0,9147	0,9162	0,9177
1,4	0,9192	0,9207	0,9222	0,9236	0,9251	0,9265	0,9279	0,9292	0,9306	0,9319
1,5	0,9332	0,9345	0,9357	0,9370	0,9382	0,9394	0,9406	0,9418	0,9429	0,9441
1,6	0,9452	0,9463	0,9474	0,9484	0,9495	0,9505	0,9515	0,9525	0,9535	0,9545
1,7	0,9554	0,9564	0,9573	0,9582	0,9591	0,9599	0,9608	0,9616	0,9625	0,9633
1,8	0,9641	0,9649	0,9656	0,9664	0,9671	0,9678	0,9686	0,9693	0,9699	0,9706
1,9	0,9713	0,9719	0,9726	0,9732	0,9738	0,9744	0,9750	0,9756	0,9761	0,9767
2,0	0,9772	0,9778	0,9783	0,9788	0,9793	0,9798	0,9803	0,9808	0,9812	0,9817
2,1	0,9821	0,9826	0,9830	0,9834	0,9838	0,9842	0,9846	0,9850	0,9854	0,9857
2,2	0,9861	0,9864	0,9868	0,9871	0,9875	0,9878	0,9881	0,9884	0,9887	0,9890
2,3	0,9893	0,9896	0,9898	0,9901	0,9904	0,9906	0,9909	0,9911	0,9913	0,9916
2,4	0,9918	0,9920	0,9922	0,9925	0,9927	0,9929	0,9931	0,9932	0,9934	0,9936
2,5	0,9938	0,9940	0,9941	0,9943	0,9945	0,9946	0,9948	0,9949	0,9951	0,9952
2,6	0,9953	0,9955	0,9956	0,9957	0,9959	0,9960	0,9961	0,9962	0,9963	0,9964
2,7	0,9965	0,9966	0,9967	0,9968	0,9969	0,9970	0,9971	0,9972	0,9973	0,9974
2,8	0,9974	0,9975	0,9976	0,9977	0,9977	0,9978	0,9979	0,9979	0,9980	0,9981
2,9	0,9981	0,9982	0,9982	0,9983	0,9984	0,9984	0,9985	0,9985	0,9986	0,9986
3,0	0,99865	0,99869	0,99874	0,99878	0,99882	0,99886	0,99889	0,99893	0,99896	0,99900
3,1	0,99903	0,99906	0,99910	0,99913	0,99916	0,99918	0,99921	0,99924	0,99926	0,99929
3,2	0,99931	0,99934	0,99936	0,99938	0,99940	0,99942	0,99944	0,99946	0,99948	0,99950
3,3	0,99952	0,99953	0,99955	0,99957	0,99958	0,99960	0,99961	0,99962	0,99964	0,99965
3,4	0,99966	0,99968	0,99969	0,99970	0,99971	0,99972	0,99973	0,99974	0,99975	0,99976
3,5	0,99977	0,99978	0,99978	0,99979	0,99980	0,99981	0,99981	0,99982	0,99983	0,99983
3,6	0,99984	0,99985	0,99985	0,99986	0,99986	0,99987	0,99987	0,99988	0,99988	0,99989
3,7	0,99989	0,99990	0,99990	0,99990	0,99991	0,99991	0,99992	0,99992	0,99992	0,99992
3,8	0,99993	0,99993	0,99993	0,99994	0,99994	0,99994	0,99994	0,99995	0,99995	0,99995
3,9	0,99995	0,99995	0,99996	0,99996	0,99996	0,99996	0,99996	0,99996	0,99997	0,99997
4,0	0,99997	0,99997	0,99997	0,99997	0,99997	0,99997	0,99998	0,99998	0,99998	0,99998

Intervalle de confiance et teste d'hypothèse

Exercice 8 *Une entreprise dispose de 100 camions pour transporter sa production. Sur une période de 30 jours choisis au hasard, elle relève le nombre suivant de camions en panne:*

5	5	6	4	6	6	8	3	5	5
5	4	3	6	5	6	4	7	6	6
5	4	3	6	5	4	5	4	5	5

1. *Calculer la moyenne $\bar{x}$ et l'écart-type s du nombre de camions en panne chaque jour pour l'échantillon étudié.*

2. *A partir des résultats obtenus pour cet échantillon, proposer une estimation de la moyenne m et de l'écart-type σ du nombre de camions en panne chaque jour pour la population correspondant aux jours ouvrés de l'année.*

3. *Déterminer un intervalle de confiance de niveau 95% de la moyenne m de la population.*

4. *Déterminer la marge d'erreur de cette estimation.*

Exercice 9 *Pour déterminer l'âge moyen de ses clients, une grande entreprise de confection pour homme prélève un échantillon aléatoire de 50 clients et trouve $\bar{x} = 36$ et $s = 12$.*

1. *Trouver un intervalle de confiance à 95% pour l'âge moyen m de l'ensemble des clients.*

2. *Supposer que pour le même seuil de confiance (95%) on veuille réduire la marge d'erreur, de façon précise, à 2 années. Quelle doit être alors la taille approximative de l'échantillon?*

3. *Quelle doit être la valeur de n si l'on veut réduire cette marge à 1?*

Exercice 10 *Vous êtes chargé de vérifier une livraison de 5000 sacs de terreau de $10kg$ chacun. Un échantillon de 100 sacs est tiré aléatoirement dans la livraison. Les 100 sacs sont pesés. On trouve $\bar{x} = 9,95kg$ et $s = 0,5kg$.*

1. *Tester si la livraison est conforme pour vous avec $\alpha = 0,05$.*

2. *Déterminer le degré de signification du test.*

Imaginons à présent que c'est vous qui êtes chargés d'envoyer cette cargaison. Vous souhaitez tester si les sacs de terreau ne de dépassent pas les $10kg$. les 100 sacs tiré aléatoirement sont pesés. On trouve $\bar{x} = 10,1kg$ et $s = 0,5kg$.

1. *Tester si la livraison est conforme pour vous avec* $\alpha = 0,02$.

2. *Déterminer le degré de signification du test.*

$$Z \sim \mathcal{N}(0,1),$$

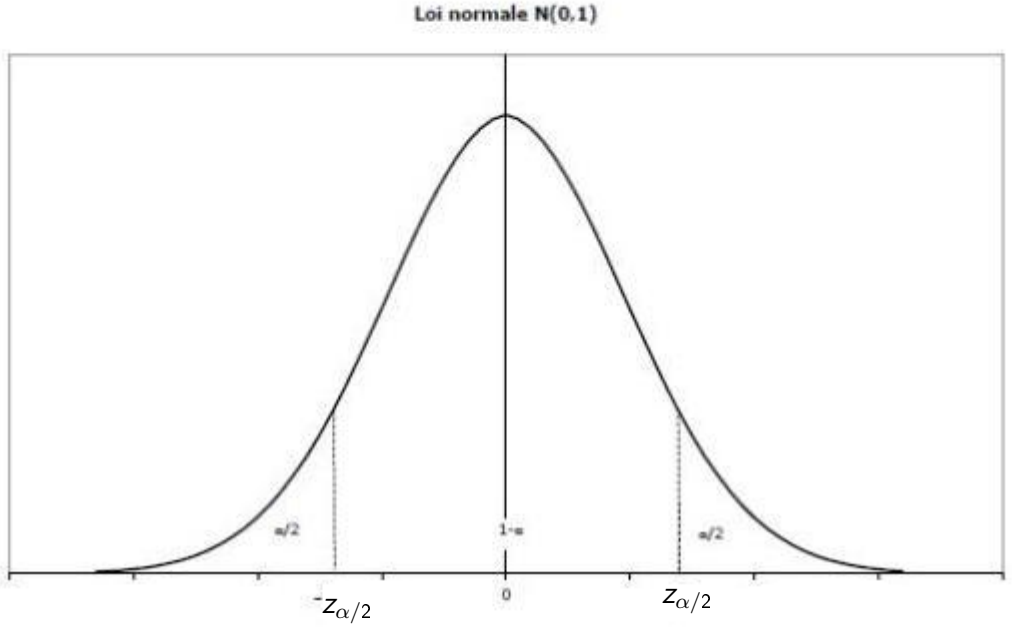

$z_{\alpha/2}$ tel que $\quad P(-z_{\alpha/2} \leq Z \leq z_{\alpha/2}) = 1 - \alpha,$

α	0,00	0,01	0,02	0,03	0,04	0,05	0,06	0,07	0,08	0,09
0,00		2,576	2,326	2,170	2,054	1,960	1,881	1,812	1,751	1,695
0,10	1,645	1,598	1,555	1,514	1,476	1,440	1,405	1,372	1,341	1,311
0,20	1,282	1,254	1,227	1,200	1,175	1,150	1,126	1,103	1,080	1,058
0,30	1,036	1,015	0,994	0,974	0,954	0,935	0,915	0,896	0,878	0,860
0,40	0,842	0,824	0,806	0,789	0,772	0,755	0,739	0,722	0,706	0,690
0,50	0,674	0,659	0,643	0,628	0,613	0,598	0,583	0,568	0,553	0,539
0,60	0,524	0,510	0,496	0,482	0,468	0,454	0,440	0,426	0,412	0,399
0,70	0,385	0,372	0,358	0,345	0,332	0,319	0,305	0,292	0,279	0,266
0,80	0,253	0,240	0,228	0,215	0,202	0,189	0,176	0,164	0,151	0,138
0,90	0,126	0,113	0,100	0,088	0,075	0,063	0,050	0,038	0,025	0,013

Régression

Exercice 11

On considère le jeu de données suivant :

x	1	2	3	4	5
y	3	4	6	7	10

On cherche à ajuster un modèle $y = ax + b$ par la méthode des moindres carrés ordinaires.

1. Calculer les moyennes $\bar{x}$ et $\bar{y}$.
2. Déterminer la covariance $\mathrm{Cov}(x, y)$ et la variance $\mathrm{Var}(x)$.
3. En déduire l'estimateur du coefficient directeur a et de l'ordonnée à l'origine b.
4. Donner l'équation de la droite de régression.
5. Prédire la valeur de y pour $x = 6$.

Exercice 12

On dispose des observations suivantes d'une variable explicative x et d'une variable réponse binaire $y \in \{0, 1\}$:

x	1	2	3	4
y	0	0	1	1

On souhaite modéliser la probabilité $p(y = 1|x)$ par un modèle logistique :

$$p(y = 1|x) = \sigma(wx + b) = \frac{1}{1 + e^{-(wx+b)}}.$$

1. Écrire la fonction de log-vraisemblance $\ell(w, b)$.
2. Donner les expressions des dérivées partielles $\frac{\partial \ell}{\partial w}$ et $\frac{\partial \ell}{\partial b}$.
3. En déduire les gradients de la log-vraisemblance négative $J(w, b) = -\ell(w, b)$.
4. On initialise $w_0 = 0$, $b_0 = 0$ et on choisit un pas $\eta = 0.5$. Calculer manuellement les deux premières mises à jour de la descente de gradient sur J.
5. Donner l'équation de la frontière de décision après chaque itération.
6. Déterminer la solution exacte par la méthode de Newton (une seule itération).

Exercise:TD AND TP

We consider a quadratic functional

$$f(x) = \frac{1}{2}\langle Ax, x\rangle - \langle b, x\rangle + c,$$

with $A \in \mathcal{M}_n(\mathbb{R})$ symmetric, $b \in \mathbb{R}^n$, $c \in \mathbb{R}$.

1. Give the expressions of the gradient and the Hessian matrix of f.
2. Under which conditions does f satisfy the hypotheses of the convergence theorem for the gradient algorithm ?
3. define f and ∇f in a way that they can be evaluated on a list of points stored as columns of a matrix. Translate it to MATLAB.
4. Recall the expression of the optimal step t^* for the gradient descent at a point x.
5. Write a MATLAB function `[Xk, FXk] = desc_gradient_fquadra(x0, eps, f, gradf, A)` that implements gradient descent with exact step for the quadratic f. The function returns the matrix `Xk` (size $n\times$#iterations) containing all iterates and the row vector `FXk` of the corresponding function values. Limit iterations to 10000.
6. Illustration in dimension $n = 2$:
   (a) For $\gamma \geq 1$ consider $A = \begin{pmatrix} 1 & 0 \\ 0 & \gamma \end{pmatrix}$, $b = (-1, 1)^T$, $c = 3$. Take $\gamma = 2$. Visualise the surface, contours and gradient field using MATLAB graphics.
   (b) Run the algorithm from $x_0 = (2.9, 1.2)^T$. On the contour plot draw the polygonal line of iterates. In a new figure, plot the error $f(x^{(k)}) - p^*$ on a semilogarithmic scale.
   (c) Repeat with $\gamma = 10$ and compare the error decays. Which γ gives faster convergence ? Why ?
7. Backtracking line search :
   (a) Write a MATLAB function `[Xk, FXk] = desc_gradient_reb(x0, eps, alph, bet, f, gradf)` that implements gradient descent with Armijo backtracking (parameters α, β).
   (b) Test it on the quadratic example with $\alpha = 0.1, \beta = 0.7$. Compare its convergence speed with the exact step version.
   (c) Verify that it also converges for the non-quadratic function
   $$f(x) = e^{x_1+3x_2-0.1} + e^{x_1-3x_2-0.1} + e^{-x_1-0.1}.$$
8. Application 2 : 1D Poisson equation.
   (a) For $n = 100$ define the tridiagonal matrix
   $$A = (n+1)^2 \begin{pmatrix} 2 & -1 & & \\ -1 & 2 & \ddots & \\ & \ddots & \ddots & -1 \\ & & -1 & 2 \end{pmatrix}, \qquad b = -1_n.$$
   Write the quadratic functional whose minimum solves $Ax = b$.

(b) Write a memory-efficient MATLAB function `[x, FXk] = desc_gradient_fquadra_der(x0, eps, f, gradf, A, b, c)` that stores only the final iterate x (and the sequence of function values for monitoring). Limit iterations to 1000.

(c) Test it on the Poisson problem. Compare with the exact solution $x^* = A \setminus (-b)$ and compute the condition number of A.

9. Application2 : Rendement annuels

Un investisseur souhaite répartir son capital entre trois actifs financiers. Les rendements annuels espérés sont :

$$\mu_1 = 8\%, \quad \mu_2 = 5\%, \quad \mu_3 = 12\%.$$

La matrice de covariance des rendements (risque) est :

$$\Sigma = \begin{pmatrix} 0,10 & 0,02 & 0,04 \\ 0,02 & 0,08 & 0,01 \\ 0,04 & 0,01 & 0,12 \end{pmatrix}.$$

On note $x = (x_1, x_2, x_3)^T$ les parts investies (pourcentages du capital). Elles doivent vérifier $x_1+x_2+x_3 = 1$ et $x_i \geq 0$. Le rendement espéré du portefeuille est $\mu^T x$ et son risque (variance) est $x^T \Sigma x$.

Formulation quadratique sans contrainte

En éliminant la variable $x_3 = 1 - x_1 - x_2$, on pose $y = (x_1, x_2)^T$. Alors :

$$x = \begin{pmatrix} x_1 \\ x_2 \\ 1 - x_1 - x_2 \end{pmatrix} = My + v, \quad M = \begin{pmatrix} 1 & 0 \\ 0 & 1 \\ -1 & -1 \end{pmatrix}, \; v = \begin{pmatrix} 0 \\ 0 \\ 1 \end{pmatrix}.$$

Le risque s'écrit :

$$\frac{1}{2} x^T \Sigma x = \frac{1}{2} y^T (M^T \Sigma M)\, y + (v^T \Sigma M)\, y + \frac{1}{2} v^T \Sigma v.$$

On définit alors la fonction quadratique (à minimiser) :

$$f(y) = \frac{1}{2} y^T Q y + q^T y + c,$$

avec $Q = M^T \Sigma M$ (symétrique définie positive), $q = (v^T \Sigma M)^T$ et $c = \frac{1}{2} v^T \Sigma v$.

Le problème initial (minimisation du risque sans contrainte de rendement) devient donc une simple minimisation sans contrainte de f sur $\mathbb{R}^2$.

Questiont : Traiter et implimenter ce problème en utilisant l'algorithme de descente de gradient (formules de l'exercice)

Arbre de Décision

Exercice 13

Un magasin souhaite prédire si un client va **acheter un produit** (OUI ou NON) en fonction de trois attributs : Âge, Revenu, et le fait d'être étudiant ou non.

Le tableau suivant présente les données collectées auprès de 8 clients :

Client	**Âge**	**Revenu**	**Étudiant ?**	**Achat**
1	Jeune	Élevé	Oui	OUI
2	Jeune	Élevé	Non	OUI
3	Moyen	Élevé	Non	OUI
4	Âgé	Faible	Non	NON
5	Âgé	Faible	Oui	NON
6	Âgé	Faible	Oui	NON
7	Moyen	Faible	Oui	OUI
8	Jeune	Faible	Non	NON

1) Calculer l'entropie initiale de l'ensemble des données.

2) Pour chaque attribut (Âge, Revenu, Étudiant), calculer :
   — L'entropie de chaque sous-groupe
   — L'entropie pondérée
   — Le gain d'information

3) Quel attribut choisir comme racine de l'arbre ? Justifier.

4) Construire l'arbre de décision complet. Détailler les développements pour les branches non pures.

5) Dessiner l'arbre de décision final.

6) Donner l'arbre final sous forme textuelle (règles SI... ALORS...).

7) Prédire la classe pour un nouveau client ayant les caractéristiques suivantes :

$$\text{Âge} = \text{Jeune}, \quad \text{Revenu} = \text{Faible}, \quad \text{Étudiant} = \text{Oui}$$

8) Écrire en pseudo-code l'algorithme de construction d'un arbre de décision (algorithme ID3).

Réduction de dimension ACP

Exercice 14

On étudie 4 étudiants selon deux caractéristiques :
— X_1 : Nombre d'heures de travail par semaine
— X_2 : Note moyenne sur 20
Les données sont les suivantes :

Étudiant	X_1 (heures)	X_2 (note)
A	10	12
B	15	14
C	5	8
D	20	16

1) Calculer la matrice des données centrées.

2) Calculer la matrice de covariance.

3) Calculer les valeurs propres et les vecteurs propres de la matrice de covariance.

4) Déterminer le pourcentage de variance expliqué par chaque composante principale.

5) Donner l'expression des deux composantes principales C_1 et C_2.

6) Projeter les 4 étudiants sur le premier axe principal.

7) Si on veut réduire à une seule dimension, quel axe choisir et pourquoi ?
non pures.

8) Représenter graphiquement les données et les axes principaux.